

# ANEXO I. Fundamentos de *Machine Learning*

## Introducción

El aprendizaje automático o *Machine Learning* (ML) es una rama de la inteligencia artificial en el que un sistema aprende a abordar por sí mismo una tarea a partir de datos sin seguir instrucciones explícitas, mejorando su rendimiento con la experiencia acumulada [33]. En nuestro contexto, un clasificador de PDAC aprende al exponerse ante más muestras etiquetadas, lo que resultará en una mejora del rendimiento y distinción entre controles sanos y pacientes PDAC.

Según la naturaleza de los datos, dentro del ML podemos distinguir entre aprendizaje supervisado y no supervisado:

- Aprendizaje supervisado: cada muestra lleva asociada una etiqueta conocida (diagnóstico del paciente) y el algoritmo aprende la relación entre los valores de los biomarcadores y la categoría diagnóstica, siendo corregido en cada iteración en función del error cometido.
- Aprendizaje no supervisado: los datos no tienen etiqueta y el algoritmo busca un patrón interno, identificando grupos de muestras similares sin conocimiento previo de su categoría.

Dado que nuestro objetivo es asignar una categoría diagnóstica a nuevas muestras de orina a partir de ejemplos con diagnóstico confirmado, nos enfocaremos en el uso de modelos de aprendizaje supervisado.

El marco matemático del aprendizaje supervisado parte de un conjunto de entrenamiento formado por muestra (vector de variables de entrada, los biomarcadores) y etiqueta (categoría diagnóstica) [33]:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n, \text{ con } x_i \in \mathbb{R}^d \text{ e } y_i \in \mathcal{Y}.$$

El objetivo es encontrar una función (hipótesis) de decisión que, dado un nuevo vector de biomarcadores, prediga su categoría diagnóstica minimizando el riesgo  $R$  (error) esperado [33]:

$$R(h) = \mathbb{E}_{(x,y) \sim P}[\mathcal{L}(h(x), y)]$$

La distribución real  $P$  de los datos es desconocida, por lo que el modelo ajusta sus parámetros para evitar equivocarse sobre las muestras disponibles [33][34]:

$$\hat{R}(h) = \frac{1}{n} \sum_{i=1}^n \mathcal{L}(h(x_i), y_i)$$

Sin embargo, minimizar el error no garantiza un buen comportamiento ante nuevas muestras. El compromiso sesgo-varianza describe como el error total de un modelo se descompone en tres elementos [35]:

$$E \left[ \left( y - \hat{f}(x) \right)^2 \right] = \underbrace{Bias^2[\hat{f}(x)]}_{\text{subajuste}} + \underbrace{Var[\hat{f}(x)]}_{\text{sobreajuste}} + \underbrace{\sigma_\varepsilon^2}_{\text{ruido irreducible}}$$

- Sesgo: error sistemático introducido por simplificaciones del modelo, este no captura la complejidad real del problema (subajuste).
- Varianza: sensibilidad del modelo a las fluctuaciones del conjunto de entrenamiento, este aprende los datos de entrenamiento pero generaliza mal a nuevas muestras (sobreajuste).
- Ruido irreducible: error inherente a los datos que ningún modelo puede eliminar, por ejemplo, la variabilidad biológica entre pacientes con el mismo diagnóstico.

Reducir el sesgo tiende a aumentar la varianza y viceversa, por lo que para gestionar este equilibrio se emplean tres mecanismos [36]:

- Regularización: añade una penalización sobre los coeficientes del modelo durante el entrenamiento (a mayor complejidad, mayor la penalización), lo que evita que el modelo se ajuste en exceso.
- Validación cruzada: divide el conjunto de entrenamiento en subconjuntos, entrenando el modelo en unos y evaluándolo en otros de forma rotativa, obteniendo así una estimación del rendimiento real ante nuevos datos.
- Ajuste de hiperparámetros: explora las configuraciones del algoritmo para encontrar la combinación que minimiza tanto el sesgo como la varianza en el problema concreto.
- 

## 5.2 Algoritmos de clasificación

### 5.2.1 Regresión Logística

La regresión logística es un modelo discriminativo que estima la probabilidad de pertenencia a una clase mediante una función logística aplicada a una combinación lineal de las variables de entrada [34]. En nuestro contexto, ante ciertos valores de biomarcadores de una muestra, estimará la probabilidad de que pertenezca a cada categoría diagnóstica.

A diferencia de la regresión lineal donde el resultado puede ser cualquier valor, la función logística o sigmoide transforma esa combinación lineal de variables en un valor entre 0 y 1, interpretable como probabilidad [33]. La frontera de decisión ( $w^T x + b = 0$ ) es el punto en el que la función sigmoide devuelve exactamente 0,5, es decir, el modelo considera que la muestra tiene igual probabilidad de pertenecer a una clase que a la otra.

Para el caso binario ( $y \in \{0,1\}$ ), la probabilidad de clase positiva (paciente con PDAC) se define como [37]:

$$p(y = 1 | \mathbf{x}; \mathbf{w}, b) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}}$$

donde  $\mathbf{w} \in \mathbb{R}^d$  es el vector de pesos que determina la importancia de cada biomarcador,  $b$  el sesgo que desplaza la frontera de decisión y  $\sigma$  la función sigmoide.

Dado que trabajamos con tres categorías diagnósticas (control sano, enfermedad benigna y PDAC), se emplea la extensión multiclase de la regresión logística, denominada softmax. En lugar de estimar una única probabilidad, el modelo estima la probabilidad de pertenencia a cada una de las tres clases, garantizando que las tres sumen 1:

$$p(y = c | \mathbf{x}) = \frac{e^{\mathbf{w}_c^\top \mathbf{x} + b_c}}{\sum_{j=1}^K e^{\mathbf{w}_j^\top \mathbf{x} + b_j}}, \quad K (\text{clases categóricas}) = 3$$

Para aprender los pesos, el modelo aplica una función que penaliza más cuanto más seguro está el modelo de una predicción errónea. Es decir, equivocarse con alta confianza se penaliza mucho más que equivocarse con incertidumbre [37]:

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$$

Para evitar el sobreajuste, se añade un término de penalización a la función de pérdida que castiga los modelos demasiado complejos. Existen dos variantes:

- Regularización L2 ( $\mathcal{L}_{reg} = \mathcal{L} + \frac{1}{2C} \|\mathbf{w}\|_2^2$ ): penaliza los coeficientes grandes de forma proporcional a su cuadrado. Esta implica que ningún biomarcador puede dominar completamente la predicción, distribuyendo la importancia entre todos y produciendo un modelo más estable.
- Regularización L1 ( $\mathcal{L}_{reg} = \mathcal{L} + \frac{1}{C} \|\mathbf{w}\|_1$ ): penaliza los coeficientes de forma proporcional a su valor absoluto. Esta lleva los coeficientes de los biomarcadores menos relevantes a cero, eliminándolos del modelo y realizando una selección automática de variables.

En ambos casos, el hiperparámetro  $C$  controla la intensidad de la penalización: a menor  $C$ , mayor regularización y modelo más simple; a mayor  $C$ , menor penalización y mayor ajuste a los datos de entrenamiento.

La regresión logística es el modelo estándar en epidemiología clínica para análisis de factores de riesgo y diagnóstico binario. Se emplea en la construcción de scores clínicos (APACHE, CURB-65, Wells) y en la identificación de biomarcadores diagnósticos [37]. En el contexto de nuestro proyecto, actúa como modelo de referencia ya que cualquier método que no supere a la regresión logística no justificaría su complejidad adicional.

### 5.2.2 Random Forest

Se trata de un modelo que combina múltiples árboles de decisión para producir una predicción más robusta que la de un árbol individual [38]. Cada árbol divide los datos de

entrenamiento en grupos más homogéneos, eligiendo en cada paso el biomarcador y el umbral de corte que mejor separan las categorías diagnósticas. La calidad de cada división se mide con la impureza de Gini, que indica cuánto se mezclan las clases en cada grupo [39]:

$$G(S) = 1 - \sum_{c=1}^K p_c^2, \quad \Delta G = G(S) - \frac{|S_L|}{|S|} G(S_L) - \frac{|S_R|}{|S|} G(S_R)$$

Para que los árboles sean distintos entre sí y no cometan los mismos errores, se introducen dos mecanismos de aleatoriedad:

- Bagging: hace que cada árbol se entrene sobre una muestra diferente del conjunto de entrenamiento, escogida con reemplazamiento: en promedio, cada árbol ve el 63% de las muestras y deja fuera el 37% restante (out-of-bag), que se usa para estimar el error sin necesidad de otro conjunto de validación.
- Subespacio aleatorio: hace que en cada nodo, en lugar de evaluar todos los biomarcadores para encontrar la mejor división, solo se considere un subconjunto aleatorio de ellos, evitando que todos los árboles se parezcan demasiado.

La predicción final se determina por votación mayoritaria entre todos los árboles:

$$\hat{y} = \underset{c}{\operatorname{argmax}} \sum_{b=1}^B 1 [h_b(x) = c]$$

La ventaja de combinar muchos árboles distintos es que los errores individuales se cancelan entre sí. Si cada árbol tiene cierta varianza y los árboles están poco correlacionados entre sí, la varianza del modelo conjunto se reduce con cada árbol adicional [38]:

$$\operatorname{Var}(\hat{y}_{RF}) = \rho \sigma^2 + \frac{1 - \rho}{B} \sigma^2 \xrightarrow{B \rightarrow \infty} \rho \sigma^2$$

Cuanto menos se parezcan los árboles entre sí (menor correlación  $\rho$ ), menor es la varianza final del modelo. Al tender el número de árboles al infinito, la varianza converge a  $\rho \sigma^2$ , controlada únicamente por esa correlación. Como subproducto, se calcula automáticamente la importancia de cada biomarcador sumando cuánto mejora la impureza en todos los nodos donde ese biomarcador fue usado para dividir:

$$\operatorname{Imp}(j) = \frac{1}{B} \sum_{b=1}^B \sum_{t \in h_b: v(t)=j} \frac{|S_t|}{n} \Delta G_t$$

El algoritmo Random Forest es uno de los clasificadores más empleados en bioinformática y diagnóstico clínico por su robustez frente al sobreajuste y su manejo de variables mixtas [39].

### 5.2.3 Support Vector Machine (SVM)

Este algoritmo busca la frontera de separación que deja el mayor margen posible entre las clases en el espacio de biomarcadores [33]. El modelo separa los grupos con la mayor holgura posible, por lo que cuanto mayor sea esa margen más robusta será la clasificación en nuevas muestras. Los puntos de entrenamiento más cercanos a la frontera son los vectores soporte y son los únicos que determinan dónde se sitúa.

Ante muestras de pacientes PDAC y control sano representadas como puntos en un plano, donde cada eje es un biomarcador, SVM busca la línea o hiperplano que separa los dos grupos dejando la mayor distancia posible entre la línea y los puntos más cercanos de cada grupo.

Cuando los datos no son perfectamente separables, como ocurre con biomarcadores que se solapan entre grupos diagnósticos, el modelo permite que algunas muestras queden en el lado incorrecto de la frontera, penalizándolas mediante variables de holgura  $\xi_i$  [40]:

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 \quad \text{s.a.} \quad y_i(w^\top x_i + b) \geq 1, \quad \forall i$$

El margen geométrico es  $\frac{2}{\|w\|}$ . Para datos no separables, se introducen variables de holgura  $\xi_i \geq 0$ :

$$\min_{w,b,\xi} \frac{1}{2} \|w\|_2^2 + C \sum_i \xi_i \quad \text{s.a.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

Ante un  $C$  grande se penaliza mucho los errores permitiendo poco solapamiento (margen estrecho, modelo más ajustado), mientras que para un  $C$  pequeño los tolera más (margen amplio, modelo más general).

Cuando la frontera de separación no es lineal, SVM transforma los datos a un espacio de mayor dimensión donde sí son separables. La formulación dual que hace esto posible es la formulación de Lagrange [40]:

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j x_i^\top x_j \quad \text{s.a.} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0$$

El kernel RBF mide la similitud entre dos muestras en función de su distancia, siendo el más empleado en la práctica:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|_2^2)$$

donde un  $\gamma$  alto hace que solo las muestras muy próximas se influyan (frontera compleja y local), y un  $\gamma$  bajo produce fronteras más suaves. Los valores óptimos de  $C$  y  $\gamma$  se seleccionan mediante validación cruzada [40].

SVM tiene aplicación en clasificación de expresión génica, clasificación de imágenes médicas y problemas con datos de alta dimensionalidad y tamaño moderado [40]. Su inclusión en permite evaluar el rendimiento de un clasificador de margen máximo con capacidad no lineal frente a los métodos de ensamble.

### 5.2.4 K-Nearest Neighbors (KNN)

Se trata de un clasificador donde una muestra nueva recibe la clase mayoritaria entre sus  $k$  vecinos más cercanos en el espacio de características [33]. Este no aprende una función durante el entrenamiento, sino que memoriza los ejemplos y al llegar una nueva muestra busca los  $k$  más parecidos y vota.

La similitud entre muestras se mide mediante la distancia euclidiana: cuanto más próximos estén dos puntos en el espacio de biomarcadores, más similares se consideran [36]:

$$\hat{y} = \underset{c}{\operatorname{argmax}} \sum_{i=1}^n 1 [d(x, x_i) \leq d(x, x_{(k)})] \cdot 1[y_i = c]$$

El valor de  $k$  controla la complejidad del modelo. Con  $k = 1$ , el modelo asigna a cada muestra nueva la clase de su vecino más cercano, muy sensible al ruido y propenso al sobreajuste. Al aumentar  $k$ , la decisión se basa en más vecinos y la frontera se suaviza, reduciendo el sobreajuste a costa de perder precisión local. El  $k$  óptimo se determina mediante validación cruzada.

KNN se emplea en reconocimiento de patrones y clasificación de imágenes médicas porque su funcionamiento no requiere asumir nada sobre la estructura de los datos, simplemente busca similitudes entre ejemplos. Si KNN obtiene un rendimiento similar al de los modelos más complejos, sugiere que la estructura de los datos es simple y no requiere modelos sofisticados. Si obtiene peor rendimiento, indica que la relación entre biomarcadores y diagnóstico requiere un modelo con mayor capacidad de generalización.

### 5.2.5 XGBoost

Este modelo se construye sumando árboles de forma secuencial, de modo que cada árbol nuevo aprende a corregir los errores del conjunto de árboles anterior [41]. A diferencia de Random Forest, donde todos los árboles se entrenan en paralelo de forma independiente, en XGBoost cada árbol depende de los anteriores y se centra en los casos donde el modelo acumulado falla.

La función combina el error de predicción y una penalización por la complejidad de cada árbol (número de hojas y magnitud de sus pesos). Esta penalización es una regularización integrada que evita que los árboles sean demasiado complejos y se sobreajusten [41]:

$$F \text{ obj} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_m \Omega(f_m), \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|_2^2$$

Para encontrar el mejor árbol en cada iteración, se aproxima la función de pérdida usando sus derivadas (gradiente  $g_i$  y hessiano  $h_i$ ) lo que le permite calcular cuánto debe valer cada hoja del árbol:

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}$$

Y cuánto mejora la predicción al dividir un nodo en dos grupos ( $L$  y  $R$ ):

$$\text{Ganancia} = \frac{1}{2} \left[ \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$$

Si esa ganancia es negativa, la división no se realiza y el árbol se poda automáticamente. Se maneja también los valores ausentes de modo que en cada nodo aprende automáticamente hacia qué rama enviar las muestras con datos faltantes.

En el contexto clínico, este modelo destaca por su rendimiento en datasets pequeños con pocas variables. Además, gestiona los valores ausentes, reduciendo la necesidad de preprocesamiento extenso y haciéndolo más transferible a entornos clínicos reales.

### 5.2.6 Gradient Boosting

Este algoritmo construye el modelo de la misma forma que XGBoost, sumando árboles secuencialmente y corrigiendo los errores del anterior, pero en su formulación estándar, sin la regularización explícita ni las optimizaciones de segundo orden que incorpora XGBoost [33].

En cada iteración el algoritmo calcula cuánto se equivoca en cada muestra (residuo) y entrena un nuevo árbol para corregir exactamente esos errores. Luego añade ese árbol al modelo con un peso controlado por la tasa de aprendizaje  $\eta$ , que determina cuánto corrige cada árbol nuevo. Un  $\eta$  pequeño hace el aprendizaje más conservador y requiere más árboles, pero produce modelos más robustos [41]:

1. Se calculan los residuos pseudo (gradiente negativo):

$$r_{im} = - \left[ \frac{\partial \mathcal{L}(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}}$$

2. Se ajusta un árbol de regresión  $h_m$  sobre  $\{(x_i, r_{im})\}$ .
3. Se actualiza  $F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x)$ .

Su inclusión permite aislar el efecto de las optimizaciones de XGBoost, ya que si ambos obtienen un rendimiento similar, la regularización y la aproximación de segundo orden aportan poco. Si XGBoost supera claramente a Gradient Boosting, esas optimizaciones son determinantes [41].

### 5.2.7 AdaBoost

Este construye el modelo de forma secuencial, como XGBoost y Gradient Boosting, pero en lugar de ajustar cada árbol sobre los residuos del error ajusta cada clasificador sobre los datos reponderados. Las muestras mal clasificadas en la iteración anterior reciben mayor peso, forzando al siguiente clasificador a prestarles más atención [42].

se entrena un clasificador simple (un árbol de profundidad 1, denominado clasificador débil) sobre las muestras con sus pesos actuales, minimizando el error ponderado. Después se calcula cuánto peso tendrá ese clasificador en la predicción final:

$$\alpha_m = \frac{1}{2} \ln \frac{1 - \varepsilon_m}{\varepsilon_m}$$

Posteriormente se actualizan los pesos de las muestras, de modo que las mal clasificadas aumentan su peso y las bien clasificadas lo reducen:

$$w_i^{(m+1)} = w_i^{(m)} \exp(-\alpha_m y_i h_m(x_i)) / Z_m$$

La predicción final combina todos los clasificadores ponderados por su precisión:

$$H(x) = \text{sgn}\left(\sum_{m=1}^M \alpha_m h_m(x)\right)$$

La principal limitación del algoritmo es su sensibilidad al ruido, ya que si una muestra es atípica o está mal etiquetada el mecanismo de reponderación puede asignarle un peso extremadamente alto, forzando a los clasificadores siguientes a ajustarse a ella a costa del rendimiento global. Su inclusión permite comparar el boosting clásico frente a las implementaciones modernas (XGBoost, Gradient Boosting) que son más robustas ante este problema [42].

## 5.3 Métricas de evaluación en contexto clínico

Equivocarse en la detección del PDAC supone no detectar un tumor (falso negativo), que es mucho más grave que generar una alarma innecesaria (falso positivo).

A partir de una matriz de confusión con verdaderos positivos (VP), falsos positivos (FP), verdaderos negativos (VN) y falsos negativos (FN), se derivan las métricas fundamentales [43]:

$$\begin{aligned} \text{Sensibilidad} &= \frac{VP}{VP + FN}, & \text{Especificidad} &= \frac{VN}{VN + FP} \\ \text{Precisión} &= \frac{VP}{VP + FP}, & F_1 &= 2 \cdot \frac{\text{Prec} \cdot \text{Sens}}{\text{Prec} + \text{Sens}} \end{aligned}$$

- Sensibilidad: mide la proporción de casos de PDAC correctamente identificados. Es la métrica prioritaria en cribado oncológico, dado que un falso negativo implica no detectar un tumor en estadio potencialmente resecable.
- Especificidad: mide la proporción de controles sanos correctamente descartados, reduciendo las pruebas diagnósticas innecesarias.
- La precisión y el F1-score resultan especialmente informativos en presencia de desbalance de clases, donde la exactitud (accuracy) puede ser engañosa.

La curva ROC representa gráficamente el equilibrio entre sensibilidad y especificidad para todos los posibles umbrales de decisión. El área bajo esa curva (AUC) resume el



rendimiento global del modelo en un único número, de modo que 0,5 equivale a clasificación aleatoria y 1,0 a clasificación perfecta. La curva se define como [43]:

$$AUC = P(\hat{f}(x^+) > \hat{f}(x^-))$$

El índice de Youden ( $J = \text{Sens} + \text{Spec} - 1$ ) identifica el umbral que maximiza simultáneamente sensibilidad y especificidad [43].

La curva de precisión-recall (PR) es complementaria en escenarios de fuerte desbalance, ya que no incorpora los VN en su cálculo, siendo más informativa sobre el rendimiento real en la clase minoritaria [43].

En el contexto de detección precoz de PDAC, donde el coste de un falso negativo supera ampliamente al de un falso positivo, la optimización de la sensibilidad tiene prioridad frente a la especificidad, orientando la selección del umbral hacia valores inferiores a 0,5.

## 5.4 Herramientas de interpretabilidad: SHAP y DALEX

La interpretabilidad de los modelos es una condición necesaria para su adopción clínica. Las herramientas de inteligencia artificial explicable (XAI) permiten comprender qué variables impulsan las predicciones tanto a nivel global como individual [44]. En este contexto, destacamos 2 herramientas de interpretabilidad:

- SHAP (Shapley Additive Explanations): se fundamenta en los valores de Shapley de la teoría de juegos cooperativos [45], que resuelve el problema de distribuir equitativamente el mérito entre varios jugadores que colaboran para obtener resultados. Adaptándolo a ML, dado un conjunto de variables de una predicción calcula cuánto contribuye cada variable al resultado final de forma justa.

Para cada paciente y variable calcula un valor que indica cuánto contribuye esa variable a desplazar la predicción desde el valor medio del modelo hacia la predicción concreta de ese paciente. Lo hace evaluando todas las combinaciones posibles de variables con y sin cada biomarcador, promediando el efecto marginal de incluirla. Matemáticamente garantiza que la suma de todos los valores SHAP de un paciente más el valor base del modelo es igual a la predicción final de ese paciente.

El valor de Shapley de la variable  $j$  para una muestra se calcula como la contribución marginal promediada sobre todas las posibles coaliciones  $S \subseteq \mathcal{F} \setminus \{j\}$ :

$$\phi_j = \sum_{S \subseteq \mathcal{F} \setminus \{j\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [v(S \cup \{j\}) - v(S)]$$

donde  $v(S)$  es el valor esperado del modelo condicionado a las variables en  $S$ . Esta fórmula garantiza cuatro propiedades axiomáticas: eficiencia ( $\sum_j \phi_j = f(x) - \mathbb{E}[f(x)]$ ), simetría, linealidad y ausencia [45].

- DALEX (Descriptive mACHINE Learning EXplanations) es un framework que mide la importancia de cada variable evaluando cuánto empeora el modelo cuando se elimina su información permutando aleatoriamente sus valores. [44]. Sus dos herramientas principales son los perfiles de dependencia parcial (PDP), que muestran cómo varía la predicción media al cambiar el valor de un biomarcador manteniendo el resto constante:

$$\text{PDP}_j(z) = \mathbb{E}_{X_{-j}}[f(z, X_{-j})] \approx \frac{1}{n} \sum_{i=1}^n f(z, x_{i,-j})$$

Y los perfiles ALE, que hacen lo mismo pero de forma más robusta cuando los biomarcadores están correlacionados entre sí.

$$\text{ALE}_j(z) = \int_{z_0}^z \mathbb{E} \left[ \frac{\partial f}{\partial x_j} | x_j = t \right] dt$$

Los diagramas de descomposición (break-down) desglosan la predicción de una instancia concreta en contribuciones secuenciales de cada variable [44]. La combinación de SHAP y DALEX permite contrastar explicaciones desde dos marcos metodológicos distintos: los valores SHAP garantizan propiedades axiomáticas rigurosas, mientras que los perfiles ALE y PDP de DALEX aportan visualizaciones continuas del efecto de cada variable sobre su dominio completo.

## 5.5 Validación cruzada y estratificación

La validación cruzada estima el error de generalización cuando el tamaño del dataset no permite una partición train/test representativa [33]. La validación cruzada k-fold lo resuelve dividiendo el dataset en  $k$  grupos y repitiendo el entrenamiento  $k$  veces, usando cada vez un grupo distinto como conjunto de evaluación  $\mathcal{D}$ :

$$\bar{R} = \frac{1}{k} \sum_{i=1}^k R(h_i, \mathcal{D}_i), \quad \hat{\sigma}^2 = \frac{1}{k-1} \sum_{i=1}^k (R_i - \bar{R})^2$$

La elección de  $k$  equilibra sesgo y varianza del estimador, es por ello que un  $k$  pequeño produce mayor sesgo (modelos entrenados con menos datos), y  $k$  grande (hasta  $k = n$ , Leave-One-Out) produce estimadores insesgados pero de alta varianza. En la práctica,  $k \in \{5, 10\}$  ofrece un buen compromiso [35].

La estratificación garantiza que en cada uno de los  $k$  grupos la proporción de clases sea la misma que en el dataset completo.

## 5.6 El problema del desbalance de clases

El desbalance de clases ocurre cuando la distribución de clases en el conjunto de entrenamiento es muy asimétrica. En clasificación de PDAC, la clase positiva es siempre minoritaria respecto a controles sanos, lo que sesga al clasificador hacia la clase mayoritaria. Para corregirlo se emplean tres estrategias [46]:

- Ponderación de clases: asigna a cada muestra un peso inversamente proporcional a la frecuencia de su clase, de modo que equivocarse en un caso de PDAC penaliza más que equivocarse en un control sano:

$$w_i = \frac{n}{k \cdot n_{y_i}}$$

- SMOTE: genera muestras de la clase minoritaria interpolando entre casos existentes, aumentando artificialmente su representación en el entrenamiento:

$$x_{nuevo} = x_i + \lambda(x_j - x_i), \quad \lambda \sim \mathcal{U}(0,1)$$

- Ajuste del umbral: desplaza el punto de corte de la decisión por debajo de 0,5, haciendo que el modelo sea más propenso a clasificar como PDAC ante la duda, priorizando la sensibilidad sobre la especificidad.